



$k_1 \dots k_n$

$h: U \rightarrow \{0, \dots, m-1\}$

Idea - mamy rodzinę funkcji hashujących

Def Niech H - rodzina funkcji hashujących $U \rightarrow \{0, \dots, m-1\}$
 H nazywamy rodziną uniwersalną:

$$\forall_{k \neq l} \left| \{ h \in H \mid h(k) = h(l) \} \right| \leq \frac{|H|}{m}$$

Przykłady takich rodzin:

1° Jeśli $|U| < m^{r+1} \ \forall \ 0 \leq a < m^{r+1}$ definiujemy h_a


$$h_a(x) = \left(\sum_{i=1}^r a_i x_i \right) \bmod m$$

$m = 2^{10}$
dzielimy

$r = 250$

na kawałki

podzielić a oraz x na bity, np.
 x ma ~ 50 bitów,
 po 10 bitów.



2° Niech p -l - pierwsza $(2p, 2p^*)$

$\forall$
 $a \in \mathbb{Z}_p^*$
 $b \in \mathbb{Z}_p$ definiujemy funkcję h_{ab}

$$h_{ab}(x) = ((ax+b) \bmod p) \bmod m$$

Tw 2° jest rodzimym uniwersalnym

Lemma 1:

Niech $h'_{ab}(x) = (ax+b) \bmod p$,

$k, l \in U, k \neq l$

$s = h'_{ab}(k), t = h'_{ab}(l)$ (a, b - dowolne, ustalone)

Wówczas $s \neq t$

d-d:

$$s = (ak+b) \bmod p$$

$$t = (al+b) \bmod p, \text{ niech } s = t, \text{ wtedy}$$

$$s - t = 0 \Rightarrow s - t \bmod p = 0 = s - t$$

$$0 = s - t = ((ak+b) \bmod p - (al+b) \bmod p) =$$

$$= a(k-l) \bmod p = 0 \Rightarrow a \in p \text{ jest pierwsze,}$$

$$k-l = 0 \Rightarrow k = l$$

Wiec
Lemma 2:

Każda funkcja $h'_{a,b}$ przekształca parę (k,l) na inną parę (s,t)

d-d:

Niech $h'_{ab}(k) = s$ oraz $h'_{ab}(l) = t$.

$$s = (ak+b) \bmod p$$

$$t = (al+b) \bmod p$$

$$s - t \bmod p = [(ak+b) - (al+b)] \bmod p = a(k-l) \bmod p$$

Czyli

$$s - t \equiv a(k-l) \bmod p \quad | \cdot (k-l)^{-1} \text{ element odwrotny } (k-l)$$

$$(s-t)(k-l)^{-1} \equiv a \cdot \underbrace{(k-l)(k-l)^{-1}}_{\substack{\text{odwrótny } (k-l) \\ \text{w } \mathbb{Z}_p^*}} \bmod p = a \quad \forall a \in \mathbb{Z}_p^*$$

Co więcej:

$$(s - ak) \bmod p = (ak+b - ak) \bmod p$$


$$\Rightarrow b = (s - ak) \bmod p = (t - al) \bmod p$$

Stąd wiadać, że istnieje bijekcja między zbiorem

funkcji $\{h_{ab} \mid a \in \mathbb{Z}_p^*, b \in \mathbb{Z}_p\}$ a zbiorem par możliwych wartości tych funkcji na różnych kluczach.

Czyli intuicyjnie, jeśli dla dwóch kluczy k i l losowo a jednolitym ppb wybieramy a, b , a takim samym ppb wybieramy wartości s, t

Obliczając prawdopodobieństwo wylosowania z tej (dla pary różnych k, l) funkcji h_{ab} możemy obliczyć prawdopodobieństwo wylosowania z tej pary wartości $(t, s) \quad t \neq s$,
teżę parę jest zła jeśli $t \equiv s \pmod{m}$




Tych przedziałów jest $\lceil \frac{p}{m} \rceil$.

W każdym przedziale jest 1 liczba dająca tę samą resztę, co t , czyli ilość tych liczb jest $\lceil \frac{p}{m} \rceil - 1 \leq \frac{p + m - 1}{m} - 1 = \frac{p-1}{m}$, ale wszystkich s -ów (dla ustalonego t) jest $p-1$, a od ppb wylosowania z tego $s \leq \frac{1}{m}$.

Słownik statyczny

- tworzymy
- wykonujemy ciąg operacji wyszukiwania



Wymagania

- pamięć $\Theta(n)$
- czas find $\Theta(1)$
- czas budowy - sensory n^2



Schematy urnowe -

n - urn
 n - kul

kule wracamy losowo do urn

Fakt: zająca urna zawiera $\Theta\left(\frac{n}{\ln(\ln(n))}\right)$ kul (oczekiwana ilość).

Przez n_0 oznaczamy ilość elementów i , t.z. $h(i) = n_0$

Idea - haszowanie dwupoziomowe

popraw funkcje
haszujące z rodziny uniwersalnych

1 - poziom:

n kluczy wrzucamy losowo do n urn

licząc, że $\sum_{j=0}^{n-1} n_j^2 = O(n)$, gdzie n_j to liczba kluczy w j -tej urnie

2 poziom:

$\forall j$ klucz z j -tej urny rozrzucamy losowo do tablicy o n_j^2 elementach, licząc, że będzie to bezkolizyjne

FAKT

Z $\Pr \geq \frac{1}{2}$ funkcja wybrana losowo z rodziny uniwersalnej umieszcza bezkolizyjnie $n = \sqrt{m}$ kluczy w tablicy m -elementowej

d-d (nie było na wykładzie, ale bitem dla sportu:-))

Niech X oznacza ilość par o tej samej wartości hasza. Można myśleć o X , jako ilości par o tej samej dacie urodzin (gdzie n - oznacza ilość osób, ilość dni w roku). Z notatki o analizie probabilistycznej, wiemy, że:

$$E[X] = \frac{n(n-1)}{2m}$$

Z nierówności Markowa:

$$\Pr(X \geq 1) \leq \frac{E[X]}{1} = \frac{n(n-1)}{2m}$$

dla $n = \sqrt{m}$ mamy:

$$\frac{\sqrt{m}(\sqrt{m}-1)}{2m} \leq \frac{m}{2m} = \frac{1}{2}$$

Zatem $\Pr(X < 1) \geq 1 - \frac{1}{2} = \frac{1}{2}$

Chcemy oszacować sumaryczny rozmiar $\sigma_{T_1}(T)$ czyli policzyć

$$E[T] = E\left[\sum_{i=0}^{n-1} n_i^2\right] = 2 E\left[\sum_{i=0}^{n-1} \frac{n_i^2 - n_i + n_i}{2}\right] = 2 \sum_{i=0}^{n-1} E\left[\frac{n_i(n_i-1)}{2}\right] + \sum_{i=0}^{n-1} E[n_i]$$

$$= 2 \cdot E\left[\sum_{i=0}^{n-1} \binom{n_i}{2}\right] + \sum_{i=0}^{n-1} E[n_i]$$

$\sum_{i=0}^{n-1} E[n_i] = n$ ponieważ zawsze suma ilości elementów w urnach da n (bo tyle elementów zawiera słownik)

$\sum_{i=0}^{n-1} E\left[\binom{n_i}{2}\right]$ — pary w urnie i -tej
to suma ilości różnych par w urnie i -tej ($\forall i=0..n-1$)
czyli ilość kolizji w i -tej urnie.

Niech X — ilość kolizji w tej urnie

$$X_{ij} = \begin{cases} 1 & \text{gdy } i, j \text{ trafiają do urny } k\text{-tej} \\ 0 & \text{wpp} \end{cases}$$

$$E[X] = \sum_{0 \leq i, j < n} E[X_{ij}] = \sum_{0 \leq i, j < n} \underbrace{P(i \text{ trafia do } k\text{-tej}) \cdot P(j \text{ trafia do } k\text{-tej})}_{\text{niezależne}}$$

$$= \binom{n}{2} \cdot \frac{1}{n^2} = \frac{n(n-1)}{2} \cdot \frac{1}{n^2} = \frac{n^2 - n}{2n^2} = \frac{n-1}{2n}$$

↑
bo sumę
robiliśmy
 $\forall \text{ par } \leq \{0..n-1\}$

Czyli $\sum_{i=0}^{n-1} E\left[\binom{n_i}{2}\right] = \sum_{i=0}^{n-1} \frac{n-1}{2n} = n \cdot \frac{n-1}{2n} = \frac{n-1}{2}$

Stąd $E\left[\sum_{i=0}^{n-1} n_i^2\right] = 2 \cdot \left(\frac{n-1}{2}\right) + n = \underline{\underline{2n-1}} < 2n$

z nierówności Markowa

$$P(T \geq 4n) \leq \frac{E(T)}{4n} = \frac{2n}{4n} = \frac{1}{2}$$

Czyli z ppb $> \frac{1}{2}$ mamy liniową ilość elementów w urnach.